Student Guide (Data Discovery and Lineage Analysis) Module 1

Student Guide (Data Discovery and Lineage Analysis)

- **EDC collects metadata**, which is data about your data (like table names, column types, usage info, etc.).
- It shows you **how data is connected**, where it comes from, and how it's used (data lineage).
- You can use smart search to quickly find the data you need.
- EDC gives a full view of all your data assets and their relationships in one place.
- It also provides analytics to help you understand how often data is used and by whom.
- Business users can search using business terms, not just technical names.
- You can add tags, comments, and business context to make data easier to understand.
- EDC helps teams trust and use data more effectively to make better decisions.

What Questions Does EDC Help Answer?

- What content does a table contain? ايه اللي جوا الجدول
- What does the data mean? البيانات اللي جوا الجدول معناها ايه
- مين اللي مسؤول عن عمل تقارير او مين عملها ?Who is responsible for creating the report •
- Where is the sensitive data located? فين اماكن البيانات الحساسة
- What does the sensitive data contain? البيانات الحساسة دي بتحتوي على ايه
- هل في مصادر تانية تحتوى على نفس البيانات دي ?Are there other sources that contain similar data •
- How do I know if the data is accurate? اعرف ازاى ان البيانات دى دقيقة
- Which are the more frequently searched assets? ايه هيا الداتا اللي بيتعمل عليها بحث و استخدام كتير
- Who are the top collaborators for my asset? تحديد الناس اللي تتعامل مع الداتا دي

EDC – Metadata Lifecycle

1-Extarct: Extract technical metadata and relationships including data lineage.

البيانات دى جات منين؟ وعدّت على إيه؟ وبقت إزاى دلوقتى؟ : Data lineage

2-Profile: Automatically run data profiling on data sources to assess key data quality statistics.

فحص وتحليل محتوى البيانات علشان تعرف جودتها: Profile

3-Classify: Auto tag semantic meaning to technical metadata.

يقوم النظام تلقانيًا بإضافة تسميات (Tags) توضح المعنى الدلالي (Semantic meaning) للمعلومات التقنية (metadata).

4-Index: Index all metadata to make it searchable.

يقوم النظام بفهرسة جميع بيانات الـ) Metadata البيانات عن البيانات (علشان تكون قابلة للبحث بسهولة.

5-Annotate: Attach business meanings and other custom annotations.

تقدر تضيف ملاحظات، تعريفات، أو معلومات إضافية على البيانات.

6-Consume: Discover, Manage, and Curate metadata across all enterprise data assets.

دور المستخدم او الديفلوبر في الدتا بقا وبيقا:

Discover (اکتشاف):

تقدر تبحث وتلاقى البيانات اللي تحتاجها بسهولة

Manage (إدارة):

(مين يستخدم إيه، تتحقق من الجودة، إلخ) metadata تنظم وتتحكم في بيانات الـ

Curate (تنظیم و تحسین):

تضيف تعريفات، تعليقات، وسوم، وتربط بين البيانات علشان تكون مفهومة ومفيدة أكتر

EDC Key Features:

EDC enables metadata extraction from multiple data sources

- View data assets extracted from various sources such as Oracle, Amazon S3, Apache Atlas, Cloudera Navigator, PowerCenter, Informatica Cloud, Informatica Platform, and many more.
- Metadata extracted from multiple sources are indexed and cataloged for faster updates, queries, and smart search results.

Components of EDC

Discovery component of EDC is available to all users with access to the catalog. However, Data Asset Analytics is accessible only to the users with additional permissions.

- **1-Discovery**: This is the component of EDC where the catalog is present with resources and assets. You can use this component to search, enrich, collaborate, and verify the quality of data that you extract from different data sources. (For Search)
- **2-Data Asset Analytics :** This is the component of EDC that you use when you want to optimize the data asset value in your data catalog by using analytics on data asset inventory, usage, enrichment, and user collaboration. (For Analysis)

Discovery:

Feature List:

1-Semantic search with intelligent facets: Semantic search with intelligent facets: Semantic search with advanced keyword search and token matching enables you to find required data sets that match the needs for your analysis.

بمعني EDC مش بيبحث بالكلمة بالظبط يعني الكلمة بالظبط يعني لو كتبت "Customer Info"، ممكن يلاقي بيانات اسم العميل، رقم الهاتف، البريد الإلكتروني، حتى لو مذكورة بأسماء مختلفة (زي cust_name, phone_num ...).

كمان تقدر تستخدم Filter (زي المصدر، النوع، التاريخ، الجودة...) علشان توصل بالضبط للبيانات اللي محتاجها.

2-Data lineage and impact analysis : You can trace the origin of data, either a summarized view or a detailed view, through lineage diagram metrics.

اقدر اشوف رحلة الداتا بتاعتي: بدأت منبن؟ اتحولت إزاى؟ وصلت لفين؟

Impact Analysis: (...) عمليات تحليل ...) يعني تشوف لو البيانات اتغيرت، إيه اللي هيتأثر بالتغيير ده (تقارير، جداول، عمليات تحليل ...) خريطة بتوريك كل خطوة البيانات عدّت بيها.

3-360-degree relationship discovery: An in-depth relationship graph that enables you to search, discover, and understand enterprise data and the relationship between them.

EDC بيعرضلك رسم بياتى يربط كل البيانات ببعض.

مدلا:

"عميل" \rightarrow "طلب" \rightarrow "منتج" \rightarrow "فاتورة" ده بيساعدك تفهم الصورة الكاملة، مش بس جزء معين.

4-Integrated data quality statistics : View data profiling statistics alongside technical metadata to understand the quality of data assets before using data for analysis. Profiling statistics include value distributions, patterns, and data type and data domain inference.

قبل ما تستخدم أي بيانات، تقدر تشوف:

- هل في قيم مفقودة؟
- هل البيانات متناسقة؟
- هل في بيانات شاذة أو مش منطقية؟

5-Automated classifications with intelligent domain and entity recognition : You can classify domains and entities such as customer, product, order, and so on, across structured and unstructured data assets. This can be done at the field, column, and table level. Apart from the inbuilt data domains, you can also create your own domain.

:بيستخدم الذكاء الاصطناعي عشان يتعرف تلقائيًا على أنواع البيانات زي EDC

Customer

- Product
- Order

6-Attributes : Attributes provide basic properties of the resource or asset. For example, you can know when the asset was created, or who made the last update.

- مين أنشأه؟
- اتعدل آخر مرة إمتى؟
 - موجود فين؟

7-Integrated Business Glossary: The integrated Business Glossary provides a central place to define and manage the lifecycle of business terms, definitions, associated reference data, related terms, links, ad hoc documentation, and notes.

Business Glossary:

- معنى المصطلحات (زي "العميل"، "المبيعات")
 - تربط المصطلح ده بالبيانات المرتبطة بيه
 - تحط تعریفات وملاحظات وروابط

8-Annotate assets: Enrich data sets by crowdsourced or expert classifications, comments, and other attributes available to anyone with appropriate security permissions.

ممكن تضيف:

- ملاحظات من خبراء البيانات
 - تعليقات من المستخدمين

(Tags)

9-Collaboration: Collaborate on assets by adding reviews, ratings, questions, following assets, and certifying assets. Collaboration on assets increases the visibility of the assets in the catalog.

- تقيّم البيانات (Rating)
 - تتابعها (Follow)
- تكتب أسئلة أو توضيحات

Semantic Search:

هو نوع متطور من البحث يفهم معنى الكلمات مش بس شكلها، وده بيساعدك تلاقي البيانات اللي محتاجها حتى لو مش كاتب الاسم بالضبط

- Intelligent search of assets) Data Assets (بحث ذكي عن طريق بيساعدك تلاقى الجداول، الأعمدة، التقارير، وكل أنواع البيانات بسرعة
- Personalized results through context-based search (نتائج مخصصه حسب محتوي البحث) البحث بياخد في اعتباره انت مين، بتشتغل على إيه، واستخدمت إيه قبل كده، ويعرضلك النتائج المناسبة ليك.
- Discover relevant data sets (اكتشاف مجموعات البيانات المناسبة)
 - تقدر تكتشف بيانات مرتبطة بتحليلك حتى لو مش كنت عارف مكانها أو اسمها الدقيق.
 - (بحث بكلمات مفتاحية متقدمة) Advanced keyword search •
 - تقدر تكتب كلمات عادية (زي "Customer orders") والنظام يفهمك ويلاقى البيانات المتصلة.
 - Search recommendations (اقتراحات للبحث)
 - بيقترح عليك كلمات بحث أو بيانات ممكن تهمك بناءً على اللي بتدور عليه.
 - (فلاتر بحث قابلة للتخصيص) Configurable search filters •

1. تقدر تضبط الفلاتر على حسب نوع البيانات، مصدرها، تاريخ آخر تعديل، الجودة... إلخ.

Trying to find the data you need across hundreds of enterprise systems may sometimes seem futile. Only through powerful semantic search built on comprehensive metadata services and a scalable infrastructure can one hope to find relevant data. EDC delivers semantic search with intelligent facets to further refine search results. Because Informatica uniquely associates business, technical, and operational metadata, business users can search business terms to find their data and then browse 360-degree relationship views to find related data assets.

Data Lineage and Impact:

يعني تتبع مصدر البيانات و التحليل التأثيري بمعني:

Data Lineage: معناها إنك تقدر تشوف رحلة البيانات كاملة — من أول ما اتجمعت أو اتنشأت، لحد ما وصلت لمكان استخدامها . النهائي . النهائي

معناها إنك تقدر تعرف إيه اللي هيتأثر لو البيانات اتغيرت أو اتعدلت : Impact Analysis

• Provides end-to-end lineage of assets from its origin to its destination

: يوضح لك كل مراحل انتقال البيانات EDC

من المصدر (زي قاعدة بيانات)
$$\leftarrow$$
 مرورًا بالتحويلات (مثل الجمع أو التصفية) \leftarrow إلى وجهتها النهائية)زي تقرير أو Dashboard)

Includes transformations and data flow

→ تقدر تشوف إيه اللي حصل للبيانات في الطريق:

اتجمعت؟ اتقسمت؟ اتنضفت؟ اتحسب منها متوسط؟

كل العمليات دي بتظهر في شكل رسم توضيحي.

· Multiple levels of lineage

تقدر تشوف مستويات مختلفة من التفاصيل حسب احتياجك:

منين جات البيانات وفين راحت : (نظرة عامة) High-level lineage

كل خطوة ومعادلة أو عملية تحويل تمت على البيانات : (تفاصيل دقيقة) Detailed lineage

Relationship Discovery:

اكتشاف العلاقات بين الداتا وبعضها:

Provides 360o relationship view

تقدر تشوف عرض شامل وكامل لكل الروابط بين أصل بيانات واحد وباقى الأصول، كأنك شايف "خريطة علاقات" حوله.

Helps discover related assets and connectivity

تساعدك تكتشف أصول بيانات مرتبطة ببعض، حتى لو مكانوش في نفس النظام أو ما كنتش تعرف إن ليهم علاقة.

• Data-sets, technical, business, semantic, and usage-based relationships

بيعرض العلاقات من كذا نوع:

- تقتية (Technical): مثلاً جدول مرتبط بعرض (View) أو قاعدة بيانات.
- تجارية (Business): مثلاً جدول مرتبط بمصطلح تجاري زي "العميل".
 - دلالية (Semantic): فهم المعنى المشترك بين البيانات.
- استخدامية (Usage-Based): مين بيستخدم البيانات؟ وبيستخدمها إزاي؟
- Tables, views, data domains, reports, and users

يربط بين:

- الجداول (Tables)
- العروض (Views)
- المجالات (Domains) زي: "المنتج"، "العميل"
 - التقارير (Reports)
- المستخدمين (Users) اللي بيشتغلوا على البيانات
- Assists progressive discovery of other data sets of interest

وانت بتتصفح أصل بيانات معين، EDC يقترح عليك أصول تانية مرتبطة أو قد تهمك، ف تكتشف بيانات جديدة بشكل تدريجي وسهل.

Data Profiling:

تحليل البيانات لاكتشاف جودتها زي اللي في IDQ

: هو عملية بتحلل محتوى البيانات في الأعمدة والجداول، علشان تقدر تعرف Data Profiling

- شكل البيانات عامل إزاي؟
 - هل فيها مشاكل؟
- هل هي مناسبة للاستخدام؟
- Provides profiling statistics along with technical metadata to review the quality of data assets
 - معلومات تقنية عن العمود (الاسم، النوع، الحجم...)
 - إحصائيات تحليلية عن المحتوى (عشان تقيم الجودة) زي القيم الفارغة و القيم المتكررة و الفريدة
- · Includes value distributions, patterns, and data type and data domain inference

Includes value distributions

يوضحلك توزيع القيم في العمود: زي مثلًا:

- كام مرة ظهرت كل قيمة؟
 - هل في تكرارات كتير؟
- هل في قيم قليلة جدًا أو نادرة؟

太 مثال: في عمود "النوع"، ممكن تلاقي:

- ذكر: 60%
- أنثى: 35%
- فارغ: 5%

Patterns

بيكشف إذا كانت البيانات ماشية على نمط معين أو لأ. مثال:

- كل أرقام التليفونات لازم تبقى: (xxx-xxxx (xxx)
 - لو في قيم خرجت عن النمط → يظهر لك المشكلة

Data Type and Domain Inference

 \leftarrow النظام بيحاول يتوقع نوع البيانات ومجالها، حتى لو مش متسجلة صريحة.

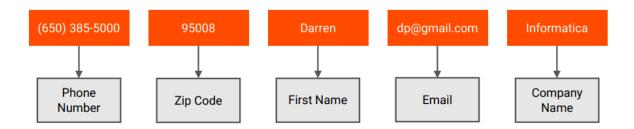
زي:

- العمود فيه أرقام زي "4000, 6500" \leftarrow ممكن يتعرف إنه "مرتبات"
 - فیه تواریخ → یتم تصنیفه ک "تاریخ میلاد" أو "تاریخ إنشاء"

Data Domains:

تصنيفات جاهزة أو معرفة مسبقًا لأنواع معينة من البيانات

بمعنى



يقدر يتعرف على الأعمدة اللي تحتوي على البيانات دي ويصنفها تلقائيًا EDC

- Data domains represent classifications of assets that you can search and retrieve from the catalog
- Examples: Social Security number, phone number, and credit card number
- · Allows you to find important data that remains undiscovered in a data source

أحيانًا الأعمدة تكون مسماة بطريقة غير واضحة، زي col_01 أو data_1 ، بس بمجرد ما EDC يحلل المحتوى، ويبان أن العمود ده بتاع: "رقم تليفون"، أو "ده إيميل"

ده هيسل عليك تعرف اسرع انهي الاعمدة ال sensitive في الداتا بتعتي

Attributes:

1-System Attributes These are predefined properties from default resource types

دي خصائص أو معلومات موجودة تلقائيًا في EDC، وبتكون مرتبطة بكل نوع من أنواع الموارد (resources) زي الجداول، الأعمدة، التقارير، إلخ.

- اسم الجدول (Table Name)
- نوع البيانات (Data Type)

- تاريخ الإنشاء (Created Date)
 - آخر تعدیل (Last Modified)
- مصدر البيانات (Source System)

بتكون موجودة بشكل تلقائي، وما تقدرش تتحكم في إضافتها أو تعديلها.

2- Custom Attributes These are properties that you can configure and assign to specific resources

خصائص إضافية أنت أو الفريق بتاعك بتضيفوها بنفسكم، عاشان توصفوا البيانات بطريقة تناسب شغلكم أو مشروعكم.

تقدر تضيف و تكتب وتعدل فيها اللي انتا عايزة

Wiki-Like Edits:

Perform quick edits of assets through the asset Overview page

اقدر من خلال ال Overview انى اعمل شرح للداتا و الاعمدة والعلاقات و ال Overview

Business Glossary Association:

Business Glossary هو مكان مركزي داخل EDC بتستخدمه علشان:

تعرف، تنظم، وتدير المصطلحات التجارية اللي بتستخدمها المؤسسة في التعامل مع البيانات.

الاستخدام الخاص بية:

1-مكان مركزي لتعريف المصطلحات (Central place to define terms):

بدل ما كل فريق يستخدم مصطلح مختلف، القاموس بيجمع كل التعاريف في مكان واحد.

2-يدير دورة حياة المصطلحات (Lifecycle of business terms): يعنى تقدر:

- تضيف مصطلح جديدتراجع وتوافق عليه
 - تحدثه
- تلغیه لما یبقی قدیم أو غیر مستخدم

3-يربط المصطلحات ب:

• بيانات مرجعية اللي تعود عليها المصطلح (Reference Data)

• مصطلحات مرتبطة ببعضها (Related Terms)

4-Workflow Automation:

القاموس يدعم تدفق عمل (Workflow) تلقائي للموافقة على المصطلحات وتنظيمها.

5-ربط المصطلحات بالبيانات الفنية (Technical Metadata):

تقدر تربط المصطلح التجاري (زي "Customer ID") بالعمود الفني اللي فعليًا فيه البيانات (cust_id مثلًا).

:يقترح الربط تلقائيًا 6-EDC

ذكي وبيقدر يقترح أي مصطلح تجاري يناسب الأعمدة أو الأصول الفنية EDC

7-استيراد المصطلحات الجاهزة:

تقدر تجيب المصطلحات من:

Informatica Business Glossary

Business Title Inference:

استنتاج العنوان تجاري للبيانات تلقائيا بمعني:

EDC

Axon

فيه الميزة دي انه يتعرف تلقائيًا على العنوان أو الاسم التجاري المناسب لأي عمود بيانات عندك، ويربطه بالمصطلحات التجارية (Business Terms).

علي عكس الBusiness Glossary انتا اللي بتضيف المسميات ويبقا مكان مجمع في كل المسميات وانه في المصطلحات و مرتبط بأنهي عمود وتعريف المصطلح تجيب مسميات من اداوت تانية

🎓 إزاي EDC بيستنتج العنوان ؟

يعتمد على 3 حاجات أساسية:

1. Data Domains

→ لو العمود يحتوي على بيانات زي أرقام بطاقات أو تليفونات، EDC يعرف تلقائيًا إنها بيانات حساسة ويربطها بمصطلح تجارى مناسب.

2. Similarity in Name

 \leftarrow لو اسم العمود قریب من اسم مصطلح تجاری، زی مثلًا:

."Customer ID" ممكن يرتبط بـ → Customer ID".

3. Column Similarity

 \leftarrow لو في أعمدة تانية مشابهة في المحتوى والشكل، EDC يستخدمها كمقارنة.

خلاص بعد ما المسميات دي البرنامج يقترحها عليا انا ممكن اعمل ايه بعد كده ؟؟؟

- Individual curation
 - نراجع كل عمود لوحده وتشوف هل التسمية صح وV محتاجة تعديل V
- Bulk curation
 - لو عندك أعمدة كتير، تقدر تراجع وتسميهم دفعة واحدة \leftarrow

فية ميزة تانية اسمها Propagation (التكرار الذكي) وظيفتها:

لما توافق على عنوان معين لعمود،

ightarrow EDC) على أعمدة تانية مشابهة في أماكن تانية Propagateيقدر ينشره تلقائيًا (ightarrow

يعني لو عندك 20 جدول فيهم أعمدة شبه بعضها، مش هتحتاج تعيد نفس التسمية يدويًا كل مرة.

User Annotation:

وظيفتها إن المستخدمين يقدروا يضيفوا كومنتات على الداتا

Collaboration:

المستخدمين يقدروا يتفاعلوا مع بعض ويتشاركوا المعرفة حول البيانات الموجودة في الكتالوج.

1. Reviews and Ratings (مراجعات وتقييمات):

- تقدر تكتب رأيك في الأصل (asset)
 - وتقيّمه بنجوم (مثلاً: 4/5)
- \leftarrow ده يساعد غيرك يعرف إذا كانت البيانات دي موثوقة أو لأ
- 2-Find most trusted assets using peer reviews:
 - من خلال التقييمات والمراجعات، تقدر توصل لأكثر الداتا ثقة بسرعة
- 3-Search assets based on the asset ratings:
- ممكن تبحث عن الأصول (assets) وتفاتر ها حسب التقييم
 → مثلاً: "هاتلى الجداول اللى تقييمها 4 نجوم أو أعلى"
- 4-Questions and Answers (أسئلة وإجابات):

- لو مش فاهم أصل معين أو محتواه، تقدر تسأل
 - وحد ويوضح لك استخدام الداتا ده

5-Follow assets and track changes (تتبع الأصول):

- تقدر تتابع أصل معين علشان توصلك إشعارات لما حد:
 - يعدّل عليه
 - يضيف له ملاحظة
 - يغير وصفه

Notification:

EDC في

بتسمح لك نتابع أي تغييرات بتحصل على البيانات أو الأصول (Assets) اللي تهمك. بمجرد ما تعمل "Follow" لأصل معين، تبدأ توصلك إشعارات لما يحصل عليه أي تغيير.



- 1. Changes to important datasets and reports
 - \leftarrow أي تعديل يحصل على جداول أو تقارير، زي زي زي تعديل

- تعديل الاسم أو الوصف
- تغيير في التصنيف أو الحساسية
 - ربط أو فصل أصل تاني

- 2. New assets introduced
 - توصلك إشعارات لو فيه →
- أصول جديدة تم إضافتها داخل البيئة الخاضعة للحوكمة (governed environment)
 - جداول أو ملفات أو تقارير جديدة ظهرت في مصدر معين
- 3. Track change impact at resource level
 - تقدر تتابع تأثیر التغییرات علی مستوی کامل، زي قاعدة بیانات أو ملف، مش بس عمود أو جدول معین \leftarrow
 - 😋 أنواع الإشعارات بتعتمد على:
 - إنت بتتابع إيه بالضبط؟
 - جدول معين؟
 - تقریر؟
 - عمود؟

أو حتى قاعدة بيانات كاملة؟

- نوع التغييرات اللي اخترت تتابعها
 - تغييرات وصفية? فنية؟ تشغيلية؟

Certification:

معناها إنك (حد تاني) بتقوم بـ اعتماد أصل بياتات (زي جدول، عمود، تقرير...) على إنه:

موثوق، دقيق، وجاهز للاستخدام في التحليل والتقارير.

إيه اللي بيحصل لما تعتمد (certify) أصل؟

- 1 أنت بتقول للناس: "البيان ده موثوق، استخدموه بأمان."
 - 2. البيانات المعتمدة بتظهر أوضح في البحث:
- ممكن تعمل فلتر في البحث علشان تشوف بس البيانات المعتمدة
- المستخدمين يقدروا يثقوا فيها بسرعة بدل ما يحتاروا بين أصول مشابهة

3. تقدر تضيف Tags (كلمات مفتاحية):

- زي "Official", "Finance", "Verified"
 - ودي بتساعد كمان في البحث عنها بسرعة

Walkthroughs:

هو دليل تفاعلي (زي محاكاة بسيطة) بيمشيك خطوة بخطوة علشان تتعلم إزاي تستخدم ميزة معينة في الكتالوج.

- تفتح علامة "Help" (علامة الاستفهام 🍞) اللي في أعلى يمين الشاشة.
 - تختار من قائمة الـ Walkthroughs المتاحة.
 - تمشي خطوة بخطوة مع الإرشادات الظاهرة.
- تقدر كمان تنفذ الخطوات بنفسك مباشرة داخل المحاكاة وكأنك شغال على النظام الحقيقي.

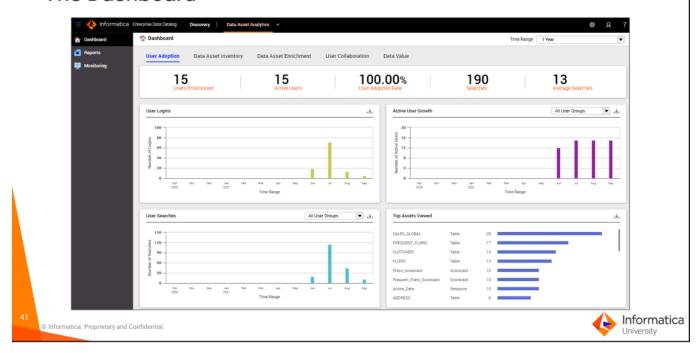
Data Asset Analytics:

Feature List

1-Dashboard:

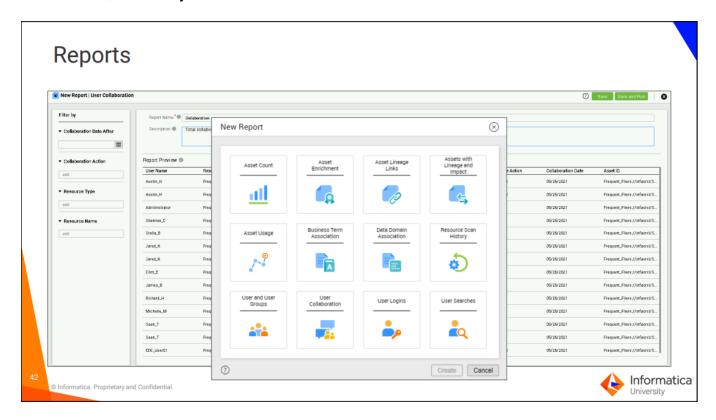
The Dashboard contains several out of-the-box charts, such as – user adoption, asset enrichment, and so on, that you can use to analyze the statistical and analytical summary of the catalog

The Dashboard



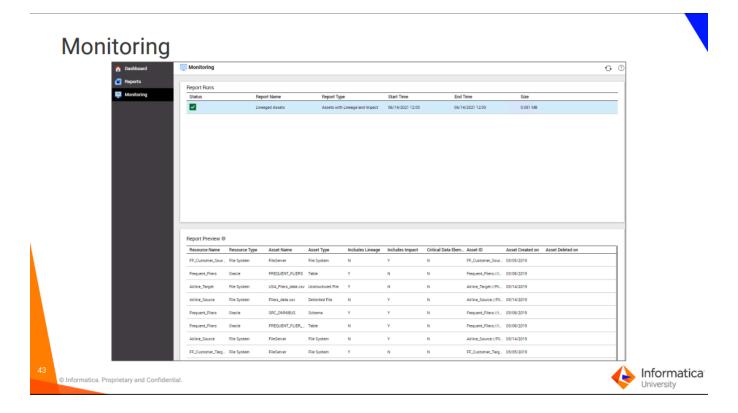
2-Reports:

You can use the Reports page to create reports to use data asset events in business intelligence tools. These events include user logins, searches, asset inventory over time, asset enrichments, and many more



3-Monitoring:

You can use the Monitoring page to view the status of report runs, download the reports in CSV format, and download the report logs



Module Summary

This module showed you how to:

- Describe data cataloging in enterprises
- Describe the metadata lifecycle in EDC
- List the key features of EDC